

Entregables Laboratorio 01

Lab Semana 1 - Communities and Crime

- Persona A: Paul Gomez Ehmgig
- Persona B: Ronnie Almeida
- Dataset: <https://archive.ics.uci.edu/static/public/183/data.csv>
- Tarea: regresión
Variable objetivo predicción: ViolentCrimesPerPop
- Descripción: Comunidades de EE.UU. los datos combinan información socioeconómica del censo de 1990, datos policiales de la encuesta LEMAS de 1990 y datos de crimen de la UCR del FBI de 1995. (fuente: <https://archive.ics.uci.edu/dataset/183/communities+and+crime>)
- Motivo: Elegimos este dataset porque combina variables socioeconómicas y demográficas con tasas de criminalidad, y tiene ~39000 faltantes repartidos en 25 columnas de diferentes tipos, lo que da material real para practicar la limpieza.

1 Link del repositorio público

https://github.com/VirtualZen/lab1_gomez_almeida

2 Capturas de pantalla:

2.1 Lista Pull requests

Filters Labels 10 Milestones 0 [New pull request](#)

☒ Clear current search query, filters, and sorts

☐	0 Open ☒ 5 Closed	Author	Label	Projects	Milestones	Reviews	Assignee	Sort
☐	docs: interpreta resultados de análisis en README #5 by ronicadena8126 (Collaborator) was merged now • Approved							4
☐	fix: integra análisis en main.py y completa README #4 by ronicadena8126 (Collaborator) was merged 53 minutes ago • Approved							5
☐	feat: análisis exploratorio y estadístico del dataset #3 by ronicadena8126 (Collaborator) was merged 1 hour ago • Approved							5
☐	feat: arreglos README.md para pruebas con -v #2 by VirtualZen (Owner) was merged 2 hours ago • Approved							4
☐	Feature/carga limpieza #1 by VirtualZen (Owner) was merged 6 hours ago • Approved							3

2.1.1 PR 1

Feature/carga limpieza #1

Merged VirtualZen merged 10 commits into main from feature/carga-limpieza 5 hours ago

Conversation 3 Commits 10 Checks 0 Files changed 15 +466 -2

VirtualZen commented 9 hours ago

Owner

Carga de pruebas unitarias, feature carga-limpieza, main.py.
Arreglo README.md
Implementación fixture
Preguntas de Investigación, hallazgos, novedades y workarounds.
Implementación de mejoras en limpieza, trazabilidad de valores y generación de un plot.

USFQ-apgomez added 9 commits yesterday

Carga inicial fuentes carga.py, test ejemplo y readme con pregunta 1

9efd087

Pruebas unitarias a la brava. Revisar ubicación de carga.py y conteni...

4cab3f6

feat: cambios carga, inicio fixture, cambio test_carga reubicando arc...

28ae000

feat: fix archivo README.md por formato pregunta 1

7e672c6

feat: arreglo fixture

398253f

feat: arreglo uso fixture y eliminación código antiguo de carga del d...

3b91a37

feat: Implementacion limpieza en carga.py y prueba unitaria con test...

b14928e

feat: mejoras proceso limpieza, trazabilidad de valores, README.md

85dc75f

feat: new main.py with pipeline and plot

0ab5627

Reviewers

USFQ-apgomez

Assignees

USFQ-apgomez

Labels

None yet

Projects

None yet

Milestone

No milestone

Development

Successfully merging this pull request may close these issues.

None yet

Notifications

Customize

Unsubscribe

You're receiving notifications because you modified the open/close state.

2.1.2 PR 2

feat: arreglos README.md para pruebas con -v #2

Merged ronicadena8126 merged 1 commit into main from feature/carga-limpieza 1 hour ago

Conversation 4 Commits 1 Checks 0 Files changed 1 +22 -2

VirtualZen commented 2 hours ago

Owner

Se modifica README.md

Como correr diagnostico datos

...

```
uv run pytest -v tests/test_carga.py
```

Correr prueba alterna de cuenta USFQ_apgomez

```
tmpdir=$(mktemp -d /tmp/uv-cache-XXXXX) && export UV_CACHE_DIR="$tmpdir" && PYTHONPATH=src uv run --active pytest -v tests/test_analisis.py
```

Hallazgos Análisis

feat: arreglos README.md para pruebas con -v 68f7665

ronicadena8126 reviewed 1 hour ago

View reviewed changes

ronicadena8126 left a comment

Collaborator

Revisé la carga y limpieza del dataset. El manejo de columnas con >80% de nulos se ve bien aplicado. Dejé un comentario sobre el copy duplicado y el workaround con UV_CACHE_DIR/PYTHONPATH, validaría la

Reviewers

ronicadena8126

Assignees

No one—assign yourself

Labels

None yet

Projects

None yet

Milestone

No milestone

Development

Successfully merging this pull request may close these issues.

None yet

Notifications

Unsubscribe

You're receiving notifications because you authored the thread.

3 participants

2.1.3 PR 3 (conflictos)

feat: análisis exploratorio y estadístico del dataset #3

Merged

ronicadena8126 merged 4 commits into `main` from `feature/analisis` 1 hour ago

Conversation 5

Commits 4

Checks 0

Files changed 5

+73 -43

ronicadena8126 commented 2 hours ago

Implementa las funciones `filtrar`, `resumen_por_grupo`, `zscore`, `top_k` y `recta_minimos_cuadrados` en `src/analisis.py`, probadas con un `DataFrame` fixture de 4 filas. Se agregó el hallazgo de Persona B y las respuestas a las preguntas de investigación en el README.

Ronnie Almeida added 2 commits 2 hours ago

feat: analisis con filtrar, zscore, top_k y regresion lineal

docs: agrega hallazgo de analisis

VirtualZen self-assigned this 1 hour ago

VirtualZen reviewed 1 hour ago

View reviewed changes

README.md

41

- En el codigo hay varios `.venv` y eso causa conflictos y el warning:

42

- `'... ../.venv' does not match the project environment path '.venv' and will be`

43

ignored; use `--active` to target the active environment instead

17

+ - (B) La tasa de crimen violento (`ViolentCrimesPerPop`) muestra una correlacion clara

con el porcentaje de poblacion bajo la linea de pobreza (`PctPopUnderPov`).

Reviewers

VirtualZen

Assignees

VirtualZen

Labels

None yet

Projects

None yet

Milestone

No milestone

Development

Successfully merging this pull request may close these issues.

None yet

Notifications

Customize

Unsubscribe

You're receiving notifications because you were assigned.

2 participants

2.1.4 PR 4

fix: integra análisis en main.py y completa README #4

Merged

VirtualZen merged 1 commit into `main` from `feature/analisis` 15 minutos ago

Conversation 5

Commits 1

Checks 0

Files changed 3

+42 -5

ronicadena8126 commented 26 minutos ago

main.py solo llamaba a `src/carga.py`; se agregan `resumen_por_grupo`, `top_k` y `recta_minimos_cuadrados`. Se actualiza el README recuperando el detalle numérico de limpieza que se había perdido al resolver el conflicto anterior.

feat: integra analisis en main.py y actualiza README con hallazgos co... 1d92ec7

VirtualZen self-assigned this 24 minutos ago

VirtualZen reviewed 21 minutos ago

View reviewed changes

README.md

```
24 24 ## Hallazgos
25 25 - (A) Aproximadamente 21 columnas fueron eliminadas por tener mas del 80% de valores
26 26 faltantes (de 128 columnas originales a 107), sin encontrarse filas duplicadas
27 27 relevantes en el dataset original.
28 28 - (B) La tasa de crimen violento (ViolentCrimesPerPop) muestra una correlacion clara
29 29 con el porcentaje de poblacion bajo la linea de pobreza (PctPopUnderPov).
```

VirtualZen 21 minutos ago

Owner

Se mueve esta sección que estaba dentro del hallazgo.

Reply...

Resolve conversation

Reviewers

VirtualZen

Assignees

VirtualZen

Labels

None yet

Projects

None yet

Milestone

No milestone

Development

Successfully merging this pull request may close these issues.

None yet

Notifications

Customize

Unsubscribe

You're receiving notifications because you modified the open/close state.

2 participants

Lock conversation

2.1.5 PR 5

docs: interpreta resultados de análisis en README #5 Code

Merged VirtualZen merged 1 commit into `main` from `feature/analisis` 2 minutes ago

Conversation 4 Commits 1 Checks 0 Files changed 1 +13

ronicadena8126 commented 10 minutos ago Collaborator

Agrega interpretación cuantitativa de resumen_por_grupo, top_k y la recta de mínimos cuadrados en la sección Hallazgos, para cumplir el criterio 'los resultados se interpretan en los hallazgos' de la rúbrica.

VirtualZen self-assigned this 9 minutos ago

VirtualZen reviewed 7 minutos ago View reviewed changes

README.md

```
... @@ -24,6 +24,19 @@ tmpdir=$(mktemp -d /tmp/uv-cache-XXXX) && export
UV_CACHE_DIR="$tmpdir" && PYTHON
24 24 ## Hallazgos
25 25 - (A) Aproximadamente 21 columnas fueron eliminadas por tener mas del 80% de valores
26 26 faltantes (de 128 columnas originales a 107), sin encontrarse filas duplicadas
relevantes en el dataset original.
- (B) La tasa de crimen violento (ViolentCrimesPerPop) muestra una correlacion clara
con el porcentaje de poblacion bajo la linea de pobreza (PctPopUnderPov).
```

VirtualZen 7 minutos ago Owner

Se agrega explicación de los hallazgos.

Reviewers

- VirtualZen** ✓

Assignees

- VirtualZen**

Labels

None yet

Projects

None yet

Milestone

No milestone

Development

Successfully merging this pull request may close these issues.

None yet

Notifications Customize

[Unsubscribe](#)

You're receiving notifications because you modified the open/close state.

2 participants

2.2 Pantalla Aprobación PR conflictos con comentarios

meet.google.com/dbq-awce-zdb?authuser=0

10:17 PM | dbq-awce-zdb

feat: análisis exploratorio y estadístico del dataset #3 Merge conflicts Code Preview

Finish your review

Write Preview Cancel Submit review

Se agregan al PR, como hay conflictos, para hacer la resolución, se sugiere recomendarle futuras para mejorar.

Comment

Submit feedback and approve these changes.

Request changes


Submit feedback suggesting changes.

Cancel **Submit review**

Paul Ehmgig (You, presenting) Stop presenting 3


Ronnie Cadena

Paul Ehmgig



2.4 Merge Fuentes

2.4.1 Evidencia falla merge automático



```
remote: Resolving deltas: 100% (4/4), done.
remote:
remote: Create a pull request for 'feature/analisis' on GitHub by visiting:
remote:   https://github.com/VirtualZen/lab1_gomez_almeida/pull/new/feature/analisis
remote:
To https://github.com/VirtualZen/lab1_gomez_almeida.git
 * [new branch]      feature/analisis -> feature/analisis
branch 'feature/analisis' set up to track 'origin/feature/analisis'.
ronnie.almeida@EC-IT00304 lab1_gomez_almeida % gh pr create \
  --base main \
  --head feature/analisis \
  --title "feat: analisis exploratorio y estadístico del dataset" \
  --body "Implementa las funciones filtrar, resumen_por_grupo, zscore, top_k y recta_minimos_cuadrados en src/analisis.py, probadas con un DataFrame fixture de 4 filas. Se agregó el hallazgo de Persona B y las respuestas a las preguntas de investigación en el README."
Creating pull request for feature/analisis into main in VirtualZen/lab1_gomez_almeida
https://github.com/VirtualZen/lab1_gomez_almeida/pull/3
ronnie.almeida@EC-IT00304 lab1_gomez_almeida % git status
On branch feature/analisis
Your branch is up to date with 'origin/feature/analisis'.

nothing to commit, working tree clean
ronnie.almeida@EC-IT00304 lab1_gomez_almeida % gh pr list


Showing 1 of 1 open pull request in VirtualZen/lab1_gomez_almeida


| ID | TITLE                                                 | BRANCH           | CREATED AT           |
|----|-------------------------------------------------------|------------------|----------------------|
| #3 | feat: analisis exploratorio y estadístico del dataset | feature/analisis | about 48 minutes ago |



ronnie.almeida@EC-IT00304 lab1_gomez_almeida % git fetch origin
remote: Enumerating objects: 91, done.
remote: Counting objects: 100% (91/91), done.
remote: Compressing objects: 100% (62/62), done.
remote: Total 83 (delta 34), reused 75 (delta 26), pack-reused 0 (from 0)
Unpacking objects: 100% (83/83), 43.04 KiB | 103.00 KiB/s, done.
From https://github.com/VirtualZen/lab1_gomez_almeida
 * [new branch]      feature/analisis_AI -> origin/feature/analisis_AI
 * [new branch]      feature/carga-limpieza -> origin/feature/carga-limpieza
 * 14aabe..d218472  main -> origin/main
ronnie.almeida@EC-IT00304 lab1_gomez_almeida % git merge origin/main
Auto-merging README.md
CONFLICT (content): Merge conflict in README.md
Auto-merging pyproject.toml
Automatic merge failed; fix conflicts and then commit the result.
ronnie.almeida@EC-IT00304 lab1_gomez_almeida %
```

2.5 Conflictos (muestra)

2.5.1 1



2.5.2 2



```
1  # Lab Semana 1 - Communities and Crime
24 ## Hallazgos
25 - (B) La tasa de crimen violento (ViolentCrimesPerPop) muestra una correlación clara con el porcentaje de población bajo
    la línea de pobreza (PctPopUnderPov).
26
27 Accept Current Change | Accept Incoming Change | Accept Both Changes | Compare Changes
28 <<<<<< HEAD (Current Change)
29 ## Decisiones de limpieza
30
31 ## Pregunta de investigación 2
32 ¿Qué diferencia hay entre correr 'pytest' a secas y 'uv run pytest'?
33
34 'uv run pytest' garantiza que las pruebas se ejecuten con el intérprete y las
35 dependencias exactas fijadas en 'uv.lock' (el '.venv' del proyecto), sin
36 necesidad de activarlo manualmente. Si en cambio alguien corre 'pytest' a
37 secas sin haber activado ese entorno virtual, puede terminar usando un
38 Python global del sistema que no tiene instaladas las dependencias del
39 proyecto (o versiones distintas), y las pruebas fallarían o darían
40 resultados no reproducibles.
41
42 =====
43 ## Hallazgos Carga
44 En la versión inicial
45 uv run pytest -q -s tests/test_check_clean.py::test_counts no se hace una limpieza completa. Se usaron valores
    configurables
46
47 before rows,cols: (1994, 128)
48 before total NaNs: 39202
49 before duplicates: 0
50 after rows,cols: (1994, 107)
51 after total NaNs: 2351
52 removed rows: 0
53 removed cols: 21
54
55 Conjunto de datos: 1994 filas y 128 columnas (Communities & Crime, UCI).
56 Antes del limpiado había 39202 valores NaN; tras aplicar la estrategia conservadora se redujeron a 2351.
57 No se encontraron filas duplicadas relevantes en el dataset original.
```

3 Post Merge, ejecuta (uv run pytest en verde)

```
Terminal Shell Edit View Window Help
lab1_gomez_almeida - zsh - 202x47
~/data_science/lab1_gomez_almeida_rps/lab-semana1 - zsh
~/data_science/laboratorio1/lab1_gomez_almeida - zsh

[ronnie.almeida@EC-IT00304 lab1_gomez_almeida] % uv run pytest -q
.....
9 passed in 12.78s
[ronnie.almeida@EC-IT00304 lab1_gomez_almeida] % uv run python main.py
Loading data from https://archive.ics.uci.edu/static/public/183/data.csv
Generating nulls report...
Nulls report:
  columna  nulos  porcentaje
0  PolicReqPerOffic  1675  84.002006
1  PolicAveoTheoried  1675  84.002006
2  PolicPerPop  1675  84.002006
3  RacialMatchCommPol  1675  84.002006
4  PctPolicWhite  1675  84.002006
..  ...  ...
123  PctEmpManu  0  0.000000
124  PctEmploy  0  0.000000
125  PctUnemployed  0  0.000000
126  PctBSorMore  0  0.000000
127  ViolentCrimesPerPop  0  0.000000

[128 rows x 3 columns]
Cleaning data (conservative defaults)...
Saving cleaned data to data/cleaned.parquet
Saving cleaning report to outputs/cleaning_report.json
Resumen por grupo de poblacion:
ViolentCrimesPerPop
  grupo_poblacion  mean  std count
Q1  0.170441  0.183509  839
Q2  0.203100  0.219764  271
Q3  0.241529  0.223773  399
Q4  0.371381  0.265027  485
Top 5 comunidades por ViolentCrimesPerPop:
  state county community communityname  fold  population  householdsize  ...  LandArea  PopDens  PctUsePubTrans  LemasPctOfficDrugUn  ViolentCrimesPerPop  OtherPerCap_was_missing  grupo_poblaci
on
1721  12  NaN  NaN  tampacity  9  0.43  0.33  ...  0.32  0.21  0.18  0.51  1.0  False
Q4
1759  6  NaN  NaN  richmondcity  9  0.12  0.45  ...  0.08  0.25  0.73  1.00  1.0  False
Q4
1295  22  NaN  NaN  alexandriacity  7  0.06  0.47  ...  0.07  0.17  0.17  0.50  1.0  False
Q4
1684  18  NaN  NaN  eastchicagocity  9  0.04  0.52  ...  0.03  0.24  0.23  0.00  1.0  False
Q3
1957  5  NaN  NaN  littlerockcity  10  0.27  0.32  ...  0.30  0.14  0.08  0.41  1.0  False
Q4

[6 rows x 188 columns]
```

4 Ejecución git log --oneline --graph --all.

```
Terminal Shell Edit View Window Help
lab1_gomez_almeida -- zsh -- 202x47

~/data_science/lab1_gomez_almeida_rps/lab-semana1 -- zsh

1295 22 NaN NaN alexandriacity 7 0.06 0.47 ... 0.07 0.17 0.17 0.50 1.0 False
Q4
1684 18 NaN NaN eastchicagocity 9 0.04 0.52 ... 0.03 0.24 0.23 0.00 1.0 False
Q3
1957 5 NaN NaN littlerockcity 10 0.27 0.32 ... 0.30 0.14 0.08 0.41 1.0 False
Q4

[5 rows x 108 columns]
Recta de minimos cuadrados: pendiente=0.5322, intercepto=0.0767
Saving figure to outputs/figura.png
Done.
ronnie.almeida@EC-IT00304 lab1_gomez_almeida % git log --oneline --graph --all
* 2536149 (HEAD -> main, origin/main, origin/HEAD) Merge pull request #4 from VirtualZen/feature/analisis
|
| * 1d92ec7 (origin/feature/analisis, feature/analisis) feat: integra analisis en main.py y actualiza README con hallazgos completos
| /
| * 87807d5 Merge pull request #3 from VirtualZen/feature/analisis
| /
| * 14038a9 fix: elimina seccion duplicada de tool.pytest.ini_options
| * 133afb2 Merge remote-tracking branch 'origin/main' into feature/analisis
| /
| /
| * d210472 Merge pull request #2 from VirtualZen/feature/carga-limpieza
| /
| * 68f7665 (origin/feature/carga-limpieza) feat: arreglos README.md para pruebas con -v
| * cdbde1a Merge pull request #1 from VirtualZen/feature/carga-limpieza
| /
| * 74b7137 feat: rename Exception to FriendlyException
| * 0ab5627 feat: new main.py with pipeline and plot
| * 85dc75f feat: mejoras proceso limpieza, trazabilidad de valores, README.md
| * 814928e feat: Implementacion limpieza en carga.py y prueba unitaria con test_check_clean.py
| * 3b91a37 feat: arreglo uso fixture y eliminacion codigo antiguo de carga del dataframe
| * 398253f feat: arreglo fixture
| * 7e672c6 feat: fix archivo README.md por formato pregunta 1
| * 28ae000 feat: cambios carga, inicio fixture, cambio test_carga reubicando archivo parquet en carpeta data
| * 4cab3f6 Pruebas unitarias a la breva. Revisar ubicacion de carga.py y contenido pyproject.toml
| * 9efd087 Carga inicial fuentes carga.py, test ejemplo y readme con pregunta 1
| /
| * 5f98213 docs: agrega hallazgo de analisis
| * 0887589 feat: analisis con filtrar, zscore, top_k y regresion lineal
| /
| * d3a158a (origin/feature/analisis_AI) feat: prueba con analisis ficticio generado con AI
| * 26938d9 feat: cambio de nombres en analisis alterno generado por AI
| /
* 144cabe chore: proyecto base con uv, estructura y README
ronnie.almeida@EC-IT00304 lab1_gomez_almeida %
```